Chapter 1: Introduction

ในประเทศไทย การรายงานสถานการณ์และข้อร้องเรียนต่างๆ ถือเป็นส่วนสำคัญในการแก้ไขปัญหาของประชาชนและพัฒนาเมือง โครงการนี้ใช้ชุดข้อมูล Traffy Fondue Dataset ซึ่งประกอบไปด้วยข้อความร้องเรียนจากประชาชน (ส่วนใหญ่อยู่ในพื้นที่กรุงเทพมหานคร) ที่ครอบคลุมปัญหาหลากหลายภาคส่วน ดังนั้นความท้าทายหลักคือ การจำแนกประเภทข้อร้องเรียนเหล่านี้ไปยังหน่วยงานที่รับผิดชอบได้อย่างถูกต้องและรวดเร็ว เนื่องจากข้อร้องเรียน 1 เรื่องอาจมีความคาบเกี่ยวและต้องใช้ความรับผิดชอบจากหลายหน่วยงานพร้อมกัน โครงงานนี้จึงถูกออกแบบมาให้อยู่ในรูปแบบของ Multi-label Text Classification (การจำแนกหลายป้ายกำกับด้วยข้อความ) โดยมีชุดข้อมูลที่ใช้ฝึกสอน (Train) จำนวน 306,419 ตัวอย่าง และชุดทดสอบ (Test) จำนวน 37,406 ตัวอย่าง แบ่งหน่วยงานที่รับผิดชอบออกเป็น 12 ป้ายกำกับ ดังนี้

1. สำนักงานตำรวจแห่งชาติ
2. การรถไฟฟ้าขนส่งมวลชนแห่งประเทศไทย
3. สภาเด็กและเยาวชนกรุงเทพมหานคร
4. กรมควบคุมมลพิษ
5. กรมสรรพสามิต
6. การไฟฟ้านครหลวง
7. กรมทางหลวง
8. สำนักงานประกันสุขภาพแห่งชาติ
9. การประปานครหลวง
10. คณะกรรมการการพัฒนาเศรษฐกิจ
11. กระทรวงการท่องเที่ยวและกีฬา
12. สำนักงาน กสทช. ศูนย์รับแจ้งปัญหา 1200

Chapter 2: Data preparation

เนื่องจากข้อมูลข้อความ (Text Data) มักมี Noise และชุดข้อมูลนี้มีปัญหาความไม่สมดุลของป้ายกำกับ (Imbalance classification) อย่างรุนแรง เพราะในบางหน่วยงานมีข้อร้องเรียนน้อยมาก สังเกตได้จากขั้นตอน Exploratory Data Analysis (EDA) ดังภาพ *(B1)*

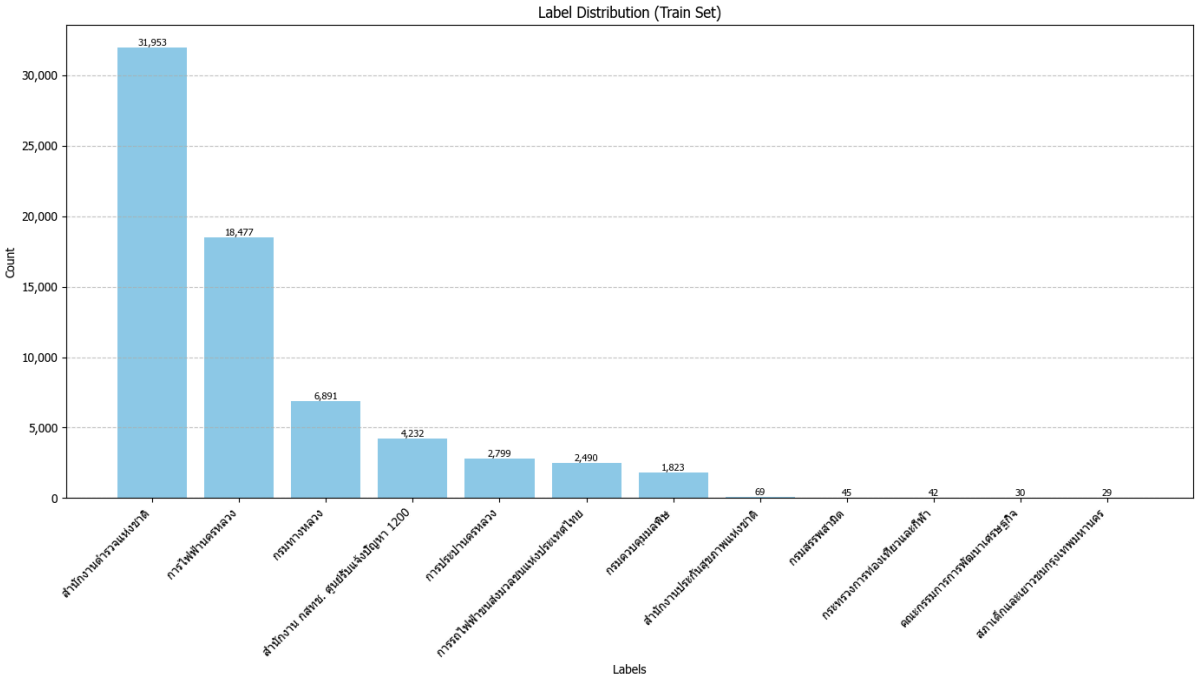

(B1)

จึงได้ดำเนินการเตรียมข้อมูลดังนี้:

1. **กรองความยาวของโทเคน (Token):** ใช้ Tokenizer ของ WangchanBERTa (airesearch/wangchanberta-base-att-spm-uncased) ในการนับจำนวนโทเคน หากพบว่าข้อร้องเรียนใดมีความยาวเกิน 512 โทเคน จะถูกตัดทิ้ง (Drop) เพื่อให้เหมาะสมกับข้อจำกัดของโมเดล Transformer พบว่ามีเพียง 835 ตัวอย่างเท่านั้นที่มีความยาวเกินข้อกำหนด ซึ่งการตัดทิ้งถือเป็นทางเลือกหนึ่งที่เหมาะสม
2. **การจัดการค่าว่าง (Missing values):** มีข้อร้องเรียนที่เป็นค่าว่างจำนวน 2,135 ตัวอย่าง ในชุดข้อมูล Train และจำนวนหนึ่งในชุดข้อมูล Test เช่นกัน จึงเลือกใช้วิธีสุ่มเก็บตัวอย่างไว้ครึ่งหนึ่ง โดยแทนที่ด้วยค่าสตริง (String) ว่างแทน เพื่อให้โมเดลยังคงได้เรียนรู้ข้อมูลในรูปแบบนี้
3. **การจัดการค่าซ้ำ (Duplicate values):** มีข้อร้องเรียนที่มีค่าซ้ำกัน 31,833 ตัวอย่าง (รวมข้อมูลที่เป็นค่าว่าง) ถูกตัดทิ้งไปในระหว่างกระบวนการจัดการค่าว่าง เพื่อไม่ให้ค่าว่างถูกตัดทิ้งไปด้วย
4. **การทำความสะอาดข้อความ (Text cleaning):** ลบ URL (http\S+), ลบช่องว่างที่มากเกินไป (\s+), และลบช่องว่างหัวท้าย (Strip) ของทุกข้อร้องเรียนเพื่อลด Noise ของข้อมูล
5. **การแบ่งชุดข้อมูล (Data splitting):** ใช้เทคนิค MultilabelStratifiedShuffleSplit เพื่อแบ่งชุดข้อมูล Train ทั้งหมด 274,857 ตัวอย่าง ออกเป็น Train (สำหรับใช้ฝึกโมเดลจริง) 80%, Validation 10% และ Test 10% จะได้ 219,885, 27,486 และ 27,486 ตัวอย่างตามลำดับ โดยยังคงสัดส่วนของแต่ละป้ายกำกับให้กระจายตัวอย่างสมดุล
6. **การจัดการความไม่สมดุลของป้ายกำกับ (Imbalance classification):** พบว่าจำนวนข้อมูลในกลุ่มป้ายกำกับส่วนน้อย (Minor) ของข้อมูล Train (ที่ถูกแบ่งแล้ว) เป็นดังนี้ *(T1)*

ป้ายกำกับ	จำนวนตัวอย่าง
คณะกรรมการการพัฒนาเศรษฐกิจ	24
สภาเด็กและเยาวชนกรุงเทพมหานคร	23
กระทรวงการท่องเที่ยวและกีฬา	34
กรมสรรพสามิต	36
สำนักงานประกันสุขภาพแห่งชาติ	55

(T1)

ซึ่งมีสัดส่วนข้อมูลของกลุ่มส่วนน้อย (นับรวมแถวที่ซ้ำกันด้วย) ต่อข้อมูลทั้งหมดน้อยมาก เพียง ~0.078% เท่านั้น จึงได้ Undersampling (สุ่มลดข้อมูล) ในกลุ่มป้ายกำกับส่วนใหญ่ (Major) ให้เหลือไม่เกิน 8,000 ตัวอย่างต่อป้ายกำกับ แล้ว Oversampling (สุ่มเพิ่มข้อมูล) โดยใช้เทคนิคสุ่มสลับตำแหน่งคำ 1 คู่ในประโยคเพื่อสร้างความหลากหลายให้ข้อมูลแบบพื้นฐาน สำหรับข้อมูลกลุ่มส่วนน้อย ที่มีจำนวนไม่ถึง 20 ตัวอย่าง (ในกรณีนี้เกิน 20 ตัวอย่างทุกป้ายกำกับก็จะถือว่าผ่านไปโดยไม่ต้องทำอะไร)

7. **การจัดการข้อมูลที่ไม่มีป้ายกำกับใด ๆ เลย (Negative Samples):** จากข้อที่ 6 ได้เพิ่มตัวอย่าง Negative กลับเข้าไปด้วยในช่วงท้ายของขั้นตอน ประมาณ 30% ของข้อมูลที่ใช้งานได้ทั้งหมด เพื่อลดปัญหา False Positives สุทธิแล้วจะเหลือข้อมูลที่ใช้ Train ได้จริงเพียง 38,747 ตัวอย่างเท่านั้น
8. **การแปลงข้อมูลเป็น Dataset:** แปลงชนิดข้อมูลของข้อร้องเรียนจากข้อความไปเป็นโทเคน ก่อนที่จะแปลงไปเป็น Dataset เพื่อใช้ร่วมกับ DataLoader ของโมเดล Transformer อีกทีหนึ่ง เพื่อลดเวลา Tokenize ในลูปการ Train โดยในขั้นตอนการ Tokenize ได้กำหนดความยาวสูงสุดของโทเคนไว้ที่ 160 โทเคน เพราะโมเดลต้องการให้โทเคนของข้อมูลมีความยาวเท่ากันในแต่ละแบตช์ (Batch) โดยค่าดังกล่าวเป็นค่าที่เหมาะสมที่สุดหากดูจากค่าเฉลี่ยซึ่งอยู่ที่ 52 โทเคน และควอนไทล์ที่ 0.95 อยู่ที่ 155 โทเคน

Chapter 3: Model

โครงงานนี้เลือกใช้โมเดล Pre-trained สัญชาติไทย WangchanBERTa (เหมือนกับ Tokenizer) จาก HuggingFace ซึ่งออกแบบมาสำหรับการประมวลผลภาษาไทยโดยเฉพาะ นำมาทำ Fine-tuning ในโหมด multi_label_classification

- **สถาปัตยกรรมและการปรับแต่ง (Modeling):**
  - ใช้โครงสร้าง AutoModelForSequenceClassification โดยมี Output Layer เท่ากับ 12 ป้ายกำกับ
  - Loss Function: ใช้เทคนิค Asymmetric Loss (ASL) ผ่านการสร้าง Custom Trainer (ASLTrainer) โดยกำหนดค่า gamma_pos = 0.0 และ gamma_neg = 2.0 วิธีนี้ช่วยแก้ปัญหา Imbalance ได้ดีกว่า Binary Cross Entropy (BCE) แบบปกติ เพราะจะโฟกัสการลงโทษ (Penalize) ฝั่ง Negative Samples เพื่อกดไม่ให้เกิด False Positive มากเกินไป
- **Hyperparameters ในการฝึกฝน:**
  - Batch Size = 64 (ใช้ Mixed Precision fp16=True เพื่อเร่งความเร็วบน GPU)
  - Learning Rate = 2×10^{-5}
  - Epochs = 8 รอบ, โดยประเมินผลผ่าน Validation Set ด้วยค่า Macro F1-Score (ใช้ Threshold ที่ 0.5 ตามค่ามาตรฐาน)
- **การหาค่า Threshold ที่เหมาะสม (Threshold Tuning):**
  - เนื่องจากเป็น Multi-label โมเดลจึงไม่ได้ใช้ค่า Threshold ที่ 0.5 เสมอไป ได้มีการเขียนลูปเพื่อทดสอบหาค่า Threshold (ตั้งแต่ 0.2 ถึง 0.9) ที่ทำให้ได้ค่า F1-Score สูงที่สุดแบบแยกอิสระในแต่ละป้ายกำกับ (Label-specific Thresholds)

Chapter 4: Results

ตาราง Classification Report ที่โมเดลทำนายบน Test dataset *(T2)*

หน่วยงาน / Label	**Precision**	**Recall**	**F1-score**	**Support**
สำนักงานตำรวจแห่งชาติ	0.7101	0.8101	0.7569	3508
การรถไฟฟ้าขนส่งมวลชนแห่งประเทศไทย	0.4842	0.5287	0.5055	261
สภาเด็กและเยาวชนกรุงเทพมหานคร	0.0000	0.0000	0.0000	4
กรมควบคุมมลพิษ	0.1970	0.4670	0.2771	197
กรมสรรพสามิต	0.6667	0.5000	0.5714	4
การไฟฟ้านครหลวง	0.6153	0.7510	0.6764	2004
กรมทางหลวง	0.3396	0.6580	0.4480	769
สำนักงานประกันสุขภาพแห่งชาติ	0.1667	0.4286	0.2400	7

การประปานครหลวง	0.4918	0.5974	0.5395	303
คณะกรรมการการพัฒนาเศรษฐกิจ	1.0000	0.3333	0.5000	3
กระทรวงการท่องเที่ยวและกีฬา	0.2500	0.2500	0.2500	4
สำนักงาน กสทช. ศูนย์รับแจ้งปัญหา 1200	0.6161	0.8845	0.7263	459
micro avg	**0.5824**	**0.7546**	**0.6574**	**7523**
macro avg	**0.4615**	**0.5174**	**0.4576**	**7523**
weighted avg	**0.6102**	**0.7546**	**0.6706**	**7523**
samples avg	**0.1856**	**0.1833**	**0.1841**	**7523**

(T2)

ภาพประกอบจาก Kaggle:

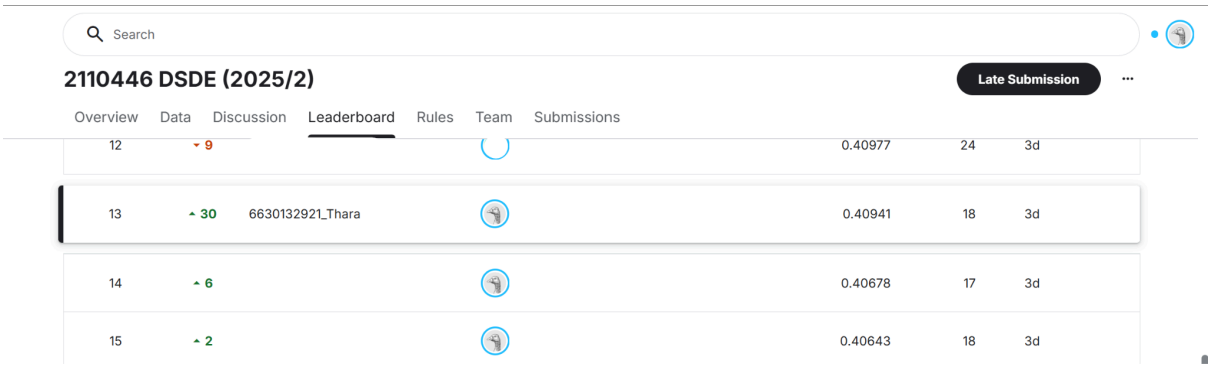

(D1)

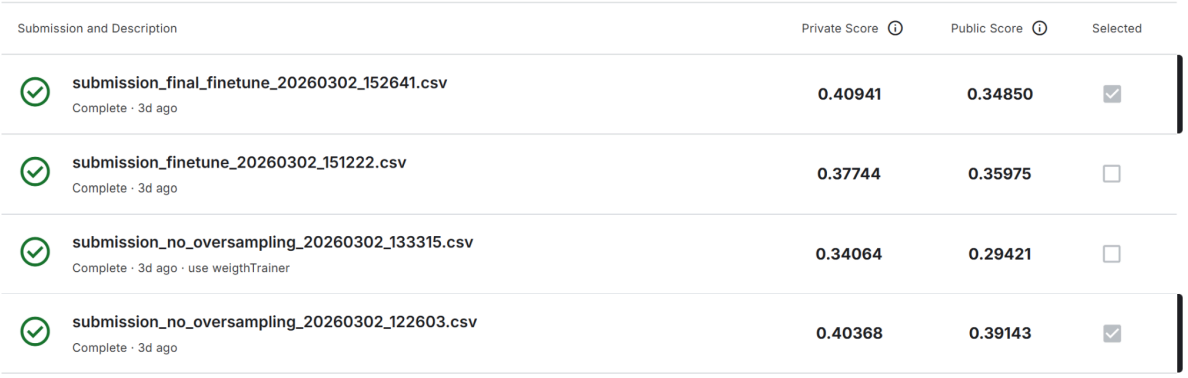

(D2)

จากการประเมินผลบน Test dataset ของโมเดลพบว่า ถึงแม้การใช้ ASL Loss ควบคู่กับการทำ Label-specific threshold tuning ช่วยให้โมเดลสามารถทำนายป้ายกำกับกลุ่มน้อย (Minority labels) ได้ดีขึ้นอย่างมีนัยสำคัญและค่า Macro F1-Score มีแนวโน้มสูงขึ้นเมื่อเทียบกับการไม่จัดการ Imbalance classification (ไม่ได้บันทึกผล Baseline ประกอบมาด้วย) แต่การประเมินผลบนชุดข้อมูลใน Kaggle ได้ค่า Macro F1-Score ที่น้อยกว่าบน Test dataset ในระดับหนึ่ง

Chapter 5: Discussion

จากการประเมินผลลัพธ์ของโมเดล สามารถแบ่งการวิเคราะห์ข้อผิดพลาด (Error Analysis) และแนวทางในการพัฒนาต่อยอด (Future Improvements) ออกเป็น 4 ประเด็นหลัก ดังนี้

1. **การวิเคราะห์ข้อผิดพลาดและพฤติกรรมของโมเดล (Error Analysis & Model Behaviors):**
    - ปัญหาค่า Recall เป็น 0 ในป้ายกำกับส่วนน้อย: จากตารางผลลัพธ์พบว่าบางป้ายกำกับ (เช่น สภาเด็กและเยาวชนกรุงเทพมหานคร) มีค่า Recall เป็น 0.0000 ซึ่งแสดงให้เห็นว่าแม้จะทำ Resampling แล้ว แต่โมเดลก็ยังไม่สามารถเรียนรู้ลักษณะเฉพาะ (Features) ของป้ายกำกับเหล่านี้ได้เพียงพอ หรือไม่กล้าทำนายป้ายกำกับนี้เลย
        - <u>แนวทางแก้ไข:</u> สำหรับป้ายกำกับที่มีข้อมูลน้อยขั้นวิกฤต (Extreme Minority) การ Resampling อาจไม่พอ ควรเปลี่ยนไปใช้ LLMs (เช่น ChatGPT, Gemini) สร้างข้อมูลสังเคราะห์ (Synthetic Data) ที่มีบริบทสมจริงขึ้นมาเติม หรือใช้ระบบ Rule-based / Keyword Matching เข้ามาครอบการทำงานของโมเดลอีกชั้น หากพบคำสั่งหรือคีย์เวิร์ดที่ชี้ชัดถึงหน่วยงานนี้ให้บังคับตอบเป็น Positive ทันที
    - ความผิดปกติในการหาค่า Threshold: จากการทำ Threshold Tuning พบว่าหลายป้ายกำกับได้ค่า Threshold ที่เหมาะสมไปกระจุกตัวอยู่ช่วงบนประมาณ 0.8 ขึ้นไป โดยในบางป้ายกำกับพุ่งไปจนถึงค่าสูงสุดที่ 0.89 ซึ่งคาดว่าโมเดลทำนายป้ายกำกับนั้นเป็นบวกทุกตัวอย่าง สิ่งนี้บ่งชี้ว่าโมเดลมีความมั่นใจ (Overconfident) ในการทำนายป้ายกำกับที่เป็น Positive สูงเกินไป ทำให้ต้องใช้เกณฑ์ตัดที่สูงมากเพื่อลด False Positives ด้วยเหตุนี้ การแจกแจงความน่าจะเป็น (Probability Distribution) ของโมเดลจึงยังไม่สมบูรณ์นัก
        - <u>แนวทางแก้ไข:</u> ควรนำเทคนิค Probability Calibration (เช่น Platt Scaling, Isotonic Regression หรือ Temperature Scaling) มาปรับระดับค่าความน่าจะเป็นที่ออกจากโมเดลให้สะท้อนความมั่นใจที่แท้จริงมากขึ้น นอกจากนี้ ในขั้นตอนการฝึกฝนควรเพิ่ม Hard Negative Samples (ข้อมูลที่คล้ายป้ายกำกับเป้าหมายแต่ไม่ใช่) และเพิ่มค่า gamma_neg ใน ASL Loss ให้สูงขึ้นอีก เพื่อบังคับให้โมเดลระมัดระวังการทาย Positive มากขึ้น
    - ความเสถียร (Generalization) ของโมเดล: พบว่าคะแนน F1-score ที่วัดผลได้จาก Test Dataset ในสภาพแวดล้อม Local มีความแตกต่าง (ได้คะแนนสูงกว่า) คะแนนที่ประเมินบนระบบของ Kaggle อย่างมีนัยสำคัญ สิ่งนี้บ่งชี้ว่าโมเดลอาจเกิดภาวะ Overfitting เล็กน้อยกับรูปแบบชุดข้อมูลที่แบ่งไว้ และยังมีความทนทาน (Robustness) ไม่พอเมื่อเจอกับข้อมูล Unseen Data แบบสมบูรณ์
        - <u>แนวทางแก้ไข:</u> ควรเปลี่ยนวิธีการแบ่งข้อมูลจากการทำ Train/Val/Test เพียงรอบเดียว (Hold-out) ไปเป็นการใช้ K-Fold Cross-Validation (เช่น 5-Fold) เพื่อให้โมเดลได้เรียนรู้และประเมินผลผ่านข้อมูลที่ครอบคลุมทุกส่วนสลับกันไป รวมถึงการเพิ่มเทคนิค Regularization ในโมเดล เช่น การเพิ่ม Dropout Rate, ใช้ Weight Decay ที่สูงขึ้น, หรือการทำ Early Stopping ที่เข้มงวดขึ้นเพื่อป้องกันไม่ให้โมเดลจำข้อความในชุดข้อมูล Train มากเกินไป
2. **การปรับปรุงกระบวนการจัดการข้อมูล (Data Processing & Pipeline Optimization):**
    - กลยุทธ์การตัดคำ (Text Truncation): ปัจจุบันเมื่อข้อความยาวเกิน 160 โทเคน โมเดลจะตัดส่วนท้ายทิ้งทั้งหมด (Head-only Truncation) ซึ่งข้อร้องเรียนบางเรื่องมักจะเกริ่นนำยาวและสรุปหน่วยงานที่ต้องรับผิดชอบไว้ตอนท้าย แนวทางแก้ไขคือควรเปลี่ยนไปใช้

เทคนิค Head + Tail Truncation (เช่น เก็บ 128 Tokens แรก และ 384 Tokens สุดท้ายมาต่อกัน) เพื่อรักษาใจความสำคัญให้ครบถ้วนยิ่งขึ้น

- การเพิ่มประสิทธิภาพโค้ด (Code Optimization): ฟังก์ชัน get_token_length ที่ใช้กรองความยาวประโยคในปัจจุบันทำงานค่อนข้างช้า และมีความซ้ำซ้อนกับกระบวนการ Tokenize เพื่อป้อนเข้าโมเดลในภายหลัง ควรยุบรวมขั้นตอนเหล่านี้เข้าด้วยกัน หรือประมวลผลแบบ Batch ผ่าน HuggingFace datasets.map() เพื่อเร่งความเร็วในการรันโค้ด
- การทำความสะอาดข้อความ (Advanced Text Cleaning): การลบแค่ URL หรือช่องว่างยังเป็นเพียงการจัดการเบื้องต้น ควรมีการทำ Text Normalization เพิ่มเติม เช่น การจัดการคำย่อที่พบบ่อยในการพิมพ์แชท การแก้คำผิด (Typo Correction) หรือการลบตัวอักษรพิเศษที่ไม่จำเป็น

3. **การจัดการความไม่สมดุลของป้ายกำกับและการเพิ่มข้อมูล (Imbalance Handling & Augmentation)**
    - ยกระดับ Data Augmentation: เทคนิค Simple Swap (สลับตำแหน่งคำ) ที่ใช้อยู่ปัจจุบันอาจทำให้บริบททางภาษาผิดเพี้ยน ในอนาคตควรเปลี่ยนไปใช้เทคนิคที่มีความหมายทางภาษาศาสตร์มากขึ้น เช่น การใช้ WordNet สำหรับภาษาไทยเพื่อหาคำพ้องความหมาย (Synonym Replacement) หรือการใช้ LLMs ช่วยทำ Paraphrasing เพื่อสร้างรูปประโยคใหม่ที่ยังคงความหมายเดิม
    - การปรับจูน Resampling Hyperparameters: ควรมีการทดลองปรับค่าพารามิเตอร์ในขั้นตอนการสุ่มข้อมูลเพิ่มเติม เช่น การปรับขอบเขต target_min (จำนวนขั้นต่ำในการ Oversampling) และ target_max (เพดานของการ Undersampling) ให้เหมาะสมกับสัดส่วนข้อมูลจริงมากกว่าการกำหนดค่าตายตัว
4. **การพัฒนาสถาปัตยกรรมโมเดลและฟังก์ชันสูญเสีย (Modeling & Loss Functions)**
    - การทดลองใช้ Pre-trained โมเดลตัวอื่น: ปัจจุบันใช้ WangchanBERTa เป็นแกนหลัก ควรมีการทดลองเปรียบเทียบกับโมเดลที่ถูกฝึกสอนมาด้วยคลังข้อมูลใหม่ๆ หรือสถาปัตยกรรมอื่น เช่น PhayaThaiBERT (ซึ่งมีประสิทธิภาพกับภาษาไทยบนโซเชียลมีเดีย), mBART, หรือการใช้ WangchanBERTa ในเวอร์ชันอื่นๆ (Variations) เพื่อหาโมเดลที่เหมาะสมที่สุด
    - การปรับปรุงฟังก์ชันสูญเสีย (Loss Function): นอกจาก Asymmetric Loss (ASL) แล้ว ควรทดลองฟังก์ชันอื่นๆ เพื่อเปรียบเทียบ เช่น การใช้ BCEWithLogitsLoss แต่เพิ่มพารามิเตอร์ pos_weight เพื่อให้น้ำหนักกับการทำนายป้ายกำกับส่วนน้อยให้ถูกต้องมากขึ้น
    - การทำ Fine-tuning ให้ละเอียดขึ้น: ควรปรับจูน Hyperparameters ในฝั่งของการฝึกฝนเพิ่ม เช่น การปรับค่าพารามิเตอร์ของ ASL loss (gamma_pos, gamma_neg) เพื่อหาระดับการลงโทษ (Penalty) ที่พอดี ไม่ทำให้โมเดลเกิดความลำเอียงจนเกินไป

Chapter 6: Conclusion

โครงงานนี้ได้นำเสนอการพัฒนาระบบ Multi-label Text Classification เพื่อจำแนกประเภทข้อร้องเรียนจากระบบ Traffy Fondue ไปยัง 12 หน่วยงานที่รับผิดชอบ โดยเลือกใช้โมเดลภาษาไทย WangchanBERTa เป็นแกนหลัก หัวใจสำคัญของความสำเร็จในเฟสนี้คือ การจัดการปัญหาความไม่สมดุลของข้อมูล (Imbalance classification) อย่างรัดกุม ผ่านเทคนิค Resampling และการเลือกใช้ Asymmetric Loss (ASL) ที่ช่วยควบคุมผลกระทบจากกลุ่มข้อมูลส่วนใหญ่ ผนวกกับการหาค่า Threshold ที่เหมาะสมเฉพาะในแต่ละป้ายกำกับ (Label-specific Thresholds) ซึ่งช่วยยกระดับค่าความแม่นยำ (F1-Score) ให้ดีขึ้นอย่างมีนัยสำคัญ

อย่างไรก็ตาม จากการประเมินผลและวิเคราะห์พฤติกรรมของโมเดล พบว่าระบบยังมี ข้อจำกัดที่ต้องได้รับการพัฒนาต่อ โดยเฉพาะการทำนายป้ายกำกับส่วนน้อยขั้นวิกฤต (Extreme Minority Labels) ที่โมเดลยังมีค่า Recall เป็นศูนย์ รวมถึงปัญหาความมั่นใจของโมเดลที่สูงเกินไป (Overconfidence) และความเสถียรของโมเดลเมื่อเจอกับข้อมูลชุดทดสอบใหม่

เพื่อยกระดับประสิทธิภาพของระบบในอนาคต ทิศทางการพัฒนาควรโฟกัสไปที่ การปรับปรุงคุณภาพข้อมูลตั้งแต่ต้นน้ำ เช่น การปรับกลยุทธ์การตัดคำ, การนำ Large Language Models (LLMs) มาช่วยสร้างข้อมูลสังเคราะห์ (Synthetic Data) เพื่อแก้ปัญหาป้ายกำกับส่วนน้อย รวมถึงการทดลองใช้โมเดลและเทคนิคใหม่ๆ เช่น PhayaThaiBERT, การทำ Probability Calibration, และการทำ K-Fold Cross Validation เพื่อลดปัญหา Overfitting

ท้ายที่สุดแล้ว แม้โมเดลในปัจจุบันจะยังมีจุดที่ต้องปรับปรุง แต่ผลลัพธ์ที่ได้ก็เป็นรากฐานที่แข็งแกร่งในการนำ AI มาช่วยลดภาระของเจ้าหน้าที่รัฐในการคัดกรองปัญหา และเป็นก้าวสำคัญที่จะช่วยให้ประชาชนได้รับการแก้ไขข้อร้องเรียนที่รวดเร็วและตรงจุดมากยิ่งขึ้นในอนาคต